

계 획 서

과제명 : Local AI 기반 생성형 AI 보안 에이전트

팀명	이 피 (IFY)
팀장	변유민
팀원	류효정, 방진수, 정시현, 김석현

1. 개발과제의 개요

본 과제는 생성형 AI 사용 과정에서 발생할 수 있는 기업 내부 정보 및 영업비밀 유출 문제를 해결하기 위한 AI 기반 보안 솔루션 「SafePromptGuard」를 개발하는 것을 목표로 한다.

최근 ChatGPT, Gemini와 같은 생성형 AI 서비스 활용이 증가하면서 개발자 및 일반 사용자들이 코드, 로그, 계약서, 내부 문서 등을 외부 AI 서비스에 입력하는 사례가 늘어나고 있다. 이 과정에서 API Key, 고객 정보, 사내 소스코드, 내부 기술 문서 등의 민감 정보가 외부로 유출될 위험이 존재한다.

기존 보안 시스템은 대부분 정규식(Regex) 또는 키워드 기반 탐지 방식에 의존하고 있어 문맥 기반의 영업비밀이나 내부 기술 정보를 효과적으로 탐지하기 어렵다는 한계가 있다. 본 과제는 이러한 문제를 해결하기 위해 정규식 기반 민감정보 탐지와 Local LLM 기반 문맥 분석 기술을 결합한 AI 보안 분석 시스템을 제안한다.

사용자가 코드 또는 문서를 업로드하면 시스템은 API Key, Password, Token, 개인정보 등 정형화된 민감정보를 우선 탐지한다. 이후 Gemma 기반 Local LLM이 문서의 의미와 문맥을 분석하여 내부 기술 문서 및 영업비밀 가능성을 판단한다. 분석 결과는 LOW, MEDIUM, HIGH 단계의 위험도로 분류되며, 탐지된 민감 정보는 자동 마스킹 처리되어 외부 AI에 안전하게 입력 가능한 형태로 변환된다. 또한 검사 결과와 위험도 로그를 저장하여 보안 관리 기능도 함께 제공한다.

본 시스템은 React 기반 사용자 인터페이스, FastAPI 기반 백엔드 서버, Ollama 환경의 Gemma 모델, SQLite 기반 로그 저장 구조로 구성된다. 또한 향후 Google Cloud Platform 환경에서의 배포 및 확장을 고려하여 설계한다.

기대효과로는 생성형 AI 사용 과정에서 발생할 수 있는 정보 유출 사고 예방, 기업 내부 데이터 보호 수준 향상, AI 기반 문맥 분석을 활용한 차세대 보안 기술 적용 등이 있다. 또한 기업 보안 시스템, 사내 AI Assistant 보안 필터, 클라우드 기반 문서 보안 서비스 등 다양한 분야에 활용 가능한 실용적 보안 솔루션으로 확장될 수 있을 것으로 기대된다.

2. 과제의 필요성 및 기대효과

(1) 기존 기술(과제)의 현황, 문제점 및 개선방안

최근 생성형 AI 서비스 활용이 급격히 증가하면서 코드 작성, 문서 요약, 로그 분석, 질의응답 등의 업무에 AI를 사용하는 사례가 확대되고 있다. 특히 개발 조직에서는 오류 로그 분석이나 코드 리뷰를 위해 외부 AI 서비스에 소스코드와 시스템 정보를 입력하는 경우가 증가하고 있으며, 일반 사무 환경에서도 계약서, 고객 데이터, 내부 정책 문서를 AI에 활용하는 사례가 늘어나고 있다.

그러나 이러한 과정에서 기업 내부 정보가 외부 AI 서비스로 전송될 가능성이 존재한다. 실제로 글로벌 기업과 보안 업계에서는 생성형 AI 사용 과정에서의 데이터 유출 위험성을 주요 보안 이슈로 다루고 있으며, 일부 기업은 내부 보안 정책을 강화하거나 생성형 AI 사용을 제한하고 있다.

현재 사용되는 DLP(Data Loss Prevention) 및 보안 필터링 시스템은 대부분 정규식 또는 키워드 기반 탐지 방식을 사용한다. 이러한 방식은 이메일, 전화번호, API Key 등 정형화된 데이터 탐지에는 효과적이지만, 문맥 기반으로 존재하는 영업비밀이나 내부 기술 정보 탐지에는 한계가 있다.

예를 들어 다음과 같은 문장은 단순 키워드 탐지만으로 탐지하기 어렵다.

“이 설계는 차세대 생산 공정 최적화를 위한 내부 알고리즘이다.”

“해당 문서는 외부 공유가 제한된 내부 운영 정책이다.”

또한 기존 보안 시스템은 탐지 후 단순 차단 기능만 제공하는 경우가 많아, 사용자가 생성형 AI를 안전하게 활용할 수 있도록 지원하는 기능이 부족하다.

본 과제에서는 이러한 문제를 해결하기 위해 정규식 기반 탐지와 Local LLM 기반 문맥 분석을 결합한 AI 보안 시스템을 제안한다. 특히 Gemma 기반 Local LLM을 활용하여 외부 API 호출 없이 내부 데이터를 분석함으로써 데이터 보안성과 실용성을 동시에 확보하고자 한다.

Gemma는 경량화된 오픈소스 LLM으로 로컬 환경에서 실행 가능하며, 기업 내부망 환경에서도 외부 데이터 전송 없이 활용할 수 있다는 장점이 있다.

(2) 과제개발 혹은 제작에 따른 기대효과

본 과제를 통해 생성형 AI 사용 과정에서 발생할 수 있는 민감정보 및 영업비밀 유출 위험을 사전에 탐지하고 차단할 수 있는 AI 기반 보안 시스템 구현이 가능할 것으로 기대된다.

우선 정형화된 민감정보를 자동 탐지 및 마스킹함으로써 사용자의 실수로 인한 정보 유출 가능성을 줄일 수 있다. 또한 Local LLM 기반 문맥 분석 기능을 통해 기존 정규식 기반 시스템이 탐지하기 어려웠던 내부 기술 문서 및 영업비밀 후보 정보를 분석할 수 있어 보안 수준 향상 효과가 기대된다.

본 시스템은 단순 차단 방식이 아니라 “안전 공유본 생성” 기능을 제공한다는 특징이 있다. 이를 통해 사용자가 생성형 AI를 보다 안전하게 활용할 수 있도록 지원하며, 기업 내부의 AI 활용성과 보안 요구사항을 동시에 만족할 수 있는 실용적 보안 구조를 제시할 수 있다.

또한 Local AI 기반 분석 구조를 적용하여 외부 AI 서비스 의존도를 줄이고, 폐쇄망 또는 기업 내부망 환경에서도 활용 가능한 구조를 제공한다. 향후 기업 보안 시스템, 개발 조직의 코드 리뷰 보안 필터, 사내 AI Assistant 보안 시스템, 클라우드 기반 문서 보안 서비스 등 다양한 분야로 확장 가능하다.

기술적으로는 생성형 AI와 보안 기술을 결합한 AI 기반 보안 시스템 구현 경험을 확보할 수 있으며, React, FastAPI, Gemma, Ollama, Google Cloud Platform 등 최신 AI 및 클라우드 기술 활용 역량 향상 효과도 기대된다.

3. 과제목표 및 내용

본 과제의 최종 목표는 생성형 AI 사용 과정에서 발생할 수 있는 민감정보 및 영업 비밀 유출 위험을 사전에 탐지하고, 안전한 형태로 변환하여 외부 AI 서비스 활용 시 정보 유출을 최소화할 수 있는 AI 기반 보안 시스템을 구현하는 것이다.

정량적 목표는 다음과 같다.

- * API Key, Password, Token 등 주요 민감정보 탐지 기능 제공
- * LOW / MEDIUM / HIGH 단계 위험도 자동 분류 기능 제공
- * 민감정보 자동 마스킹 기능 제공
- * 텍스트 및 파일 업로드 기반 검사 기능 제공
- * 검사 결과 및 로그 저장 기능 제공
- * React 기반 웹 인터페이스 구축
- * Local LLM(Gemma) 기반 문맥 분석 기능 적용
- * 5초 이내 기본 분석 결과 출력 목표
- * 주요 민감정보 패턴 탐지 정확도 향상

정성적 목표는 다음과 같다.

- * 기존 정규식 기반 탐지 시스템의 한계를 보완하는 문맥 기반 AI 보안 분석 구현
- * 생성형 AI 활용과 보안 요구사항을 동시에 만족할 수 있는 실용적 구조 제시
- * Local AI 기반 데이터 보호 환경 구축
- * AI 기반 보안 자동화 시스템 구현
- * 실제 기업 환경 적용 가능성을 고려한 보안 솔루션 설계

본 과제의 주요 개발 범위는 다음과 같다.

첫째, 사용자가 텍스트 또는 파일 형태의 코드 및 문서를 업로드할 수 있는 웹 기반 인터페이스를 구현한다. 업로드 대상은 소스코드, 로그 파일, 설정 파일, 문서 파일 등을 포함한다.

둘째, 정규식 기반 민감정보 탐지 기능을 구현한다. 이를 통해 API Key, JWT, Password, 데이터베이스 접속 정보, 이메일, 전화번호 등의 정형화된 데이터를 탐지한다.

셋째, Gemma 기반 Local LLM을 활용한 문맥 분석 기능을 구현한다. 이를 통해 내부 기술 문서, 운영 정책, 비공개 알고리즘 등 정규식 기반 탐지만으로 식별하기 어려운 영업비밀 후보 정보를 분석한다.

넷째, 분석 결과를 기반으로 위험도를 LOW, MEDIUM, HIGH 단계로 분류하고 탐지 사유를 사용자에게 제공한다.

다섯째, 탐지된 민감 정보를 자동 마스킹 처리하여 외부 AI 서비스에 안전하게 활용 가능한 문서를 생성한다.

여섯째, 검사 결과 및 로그 저장 기능을 구현하여 보안 감사 및 이력 관리가 가능하도록 구성한다.

본 과제의 비기능적 요구사항은 다음과 같다.

- * 성능 측면에서는 일반적인 텍스트 및 코드 파일 업로드 시 빠른 응답 속도를 제공하도록 설계한다.
- * 보안 측면에서는 Local LLM 기반 분석 구조를 적용하여 내부 데이터가 외부 API로 전송되지 않도록 구성한다.
- * 유지보수성 측면에서는 프론트엔드, 백엔드, AI 분석 모듈을 분리하여 기능 확장과 관리가 용이한 구조로 설계한다.
- * 확장성 측면에서는 향후 Google Cloud Platform 환경에서의 배포 및 추가 AI 모델 연동이 가능하도록 설계한다.
- * 사용성 측면에서는 위험도 시각화와 마스킹 결과 제공을 통해 비전문가도 쉽게 활용 가능한 UI를 목표로 한다.

4. 추진전략 및 방법

(1) 추진전략 및 방법

본 과제는 생성형 AI 사용 과정에서 발생할 수 있는 민감정보 및 영업비밀 유출 문제를 해결하기 위해 “정규식 기반 탐지 + Local LLM 기반 문맥 분석” 구조를 결합한 AI 보안 시스템 개발을 목표로 한다. 이를 위해 단계적 개발 절차와 모듈 분리형 구조를 기반으로 프로젝트를 추진한다.

우선 자료수집 단계에서는 생성형 AI 보안 이슈, DLP(Data Loss Prevention) 시스템, API Key 유출 사례, 기업 내부 보안 정책 사례 등을 조사한다. 또한 GitHub 및 공개 보안 문서를 기반으로 주요 민감정보 패턴과 탐지 규칙을 수집하고, 실제 개발 환경에서 사용되는 환경설정 파일 및 인증 정보 형태를 분석하여 탐지 룰 설계에 반영한다.

환경 구축 단계에서는 React 기반 프론트엔드 환경과 FastAPI 기반 백엔드 서버를 구축하고, Ollama 환경에서 Gemma 모델을 로컬 실행할 수 있도록 AI 분석 환경을 구성한다. 이후 프론트엔드, 백엔드, AI 모델 간 API 통신 구조를 구축하여 통합형 시스템으로 개발한다.


개발은 기능 단위 모듈화 방식으로 진행한다. 먼저 정규식 기반 민감정보 탐지 기능을 구현하여 API Key, Password, JWT, 이메일, 전화번호 등 정형화된 데이터를 탐지한다. 이후 Gemma 기반 문맥 분석 기능을 추가하여 내부 기술 문서, 비공개 정책, 영업비밀 후보 문장 등을 분석할 수 있도록 구성한다.

분석 결과는 LOW, MEDIUM, HIGH 단계의 위험도로 분류되며, 탐지 사유와 함께 사용자에게 제공된다. 또한 탐지된 민감 정보는 자동 마스킹 처리되어 외부 AI 서비스에 안전하게 입력 가능한 형태로 변환된다.

프로젝트의 안정성과 유지보수성을 위해 프론트엔드, 백엔드, AI 분석 모듈을 분리된 구조로 설계하며, SQLite 기반 로그 저장 구조를 적용하여 검사 이력 관리 기능도 함께 구현한다. 이후 Google Cloud Platform 환경에서의 배포 가능성을 고려하여 Docker 기반 배포 구조와 클라우드 연동도 검토한다.

또한 GitHub 기반 버전 관리와 역할별 브랜치 분리를 통해 협업 효율성을 확보하고, 기능별 테스트 및 통합 테스트를 반복 수행하여 시스템 안정성을 검증할 예정이다.

<시스템 아키텍처>



(2) 추진체계

본 과제는 총 5인으로 구성된 팀 프로젝트로 진행하며, 프론트엔드, 백엔드, AI 분석, 보안 탐지, 시스템 통합 분야로 역할을 분담하여 개발을 수행한다.

구분	담당자	역할
팀장 / 시스템 통합	변유민	전체 프로젝트 관리, 시스템 구조 설계, 기능 통합, 일정 관리, 발표 및 최종 검토
프론트엔드 개발	류효정	React 기반 사용자 인터페이스 개발 및 결과 시각화 구현
AI 분석 및 모델 연동	방진수	Gemma 기반 Local LLM 연동 및 위험도 분석 로직 구현
백엔드 개발	정시현	FastAPI 기반 서버 및 파일 분석 API 구현
보안 탐지 및 시스템 구현	김석현	정규식 기반 민감정보 탐지 및 자동 마스킹 기능 구현

프로젝트는 기능 단위 협업 구조로 진행하며, 프론트엔드·백엔드·AI 모듈 간 API 명세를 사전에 정의하여 병렬 개발이 가능하도록 구성한다.

또한 GitHub 기반 버전 관리와 코드 리뷰를 통해 협업 효율성을 확보하고, 기능별 테스트 및 통합 테스트를 반복 수행하여 시스템 안정성을 검증할 예정이다.

특히 AI 분석 결과의 정확성과 보안 신뢰성을 확보하기 위해 테스트 데이터를 구축하고 반복 검증을 수행할 계획이다.

5. 추진일정

세부내용	수행기간(주)															비고
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	
요구사항 분석 및 자료조사																
시스템 아키텍처 설계																
개발 환경 구축 및 역할 분담																
프론트엔드 UI 개발																
백엔드 API 개발																
Regex 기반 민감정보 탐지 개발																
Gemma 기반 문맥 분석 구현																
위험도 분석 및 마스킹 기능 구현																
로그 저장 및 DB 연동																
통합 테스트 및 오류 수정																
UI 개선 및 시각화 고도화																
Google Cloud 배포 및 연동																
최종 발표자료 및 시연 준비																
최종 점검 및 문서 정리																

6. 참고문헌

1. Google DeepMind, "Gemma Models Overview," Google AI for Developers, 2025.
2. Gemma Team, "Gemma 3 Technical Report," Google DeepMind, 2025.
3. OWASP Foundation, "OWASP Top 10 for Large Language Model Applications," 2025.
4. OWASP Foundation, "OWASP GenAI Security Project," 2025.
5. Google Cloud, "Sensitive Data Protection (Cloud DLP) Documentation," 2025.
6. Google Cloud, "Cloud Data Loss Prevention (Cloud DLP)," Google Cloud Security, 2025.
7. Google Cloud, "Cloud Data Loss Prevention (Cloud DLP) Overview," Google Cloud Blog, 2022.
8. Mohammad Fasha et al., "Mitigating the OWASP Top 10 For Large Language Models Applications using Intelligent Agents," arXiv, 2026.
9. Nourin Shahin, Izzat Alsmadi, "Benchmarking LLAMA Model Security Against OWASP Top 10 For LLM Applications," arXiv, 2026.
10. Google DeepMind, "Gemma," Google DeepMind Official Model Page, 2025.