

계 획 서

과제명 : 설비 다운타임 최소화를 위한 Workflow 기반 RAG 장애
조치 에이전트

팀명	UnHarnesedYU
팀장	이진녕
팀원	안태언

1. 개발과제의 개요

본 과제는 산업 현장에서 설비 장애 발생 시, 작업자가 방대한 종이/PDF 매뉴얼을 직접 탐색하며 발생하는 초기 대응 지연 및 설비 다운타임 문제를 해결하기 위한 AI 기반 장애 조치 지원 시스템 개발을 목표로 한다.

기존 산업 현장에서는 장애 발생 시 숙련 작업자의 경험에 의존하거나 비정형 매뉴얼을 직접 검색해야 하는 한계가 존재하며, 이는 초기 대응 지연 및 유지보수 효율 저하로 이어진다.

이를 해결하기 위해 본 과제는 검색 증강 생성(RAG) 기반 구조를 적용하여, 사용자가 입력한 에러 코드 및 증상에 대해 관련 매뉴얼 내용을 검색하고, 작업자의 응답 및 현재 설비 상태에 따라 단계별 조치 절차를 제공하는 대화형 워크플로우 기반 Agent를 구현한다.

또한 AI가 매뉴얼 외부의 정보를 기반으로 임의 응답을 생성하지 않도록 제한하고, 출처 기반 응답 구조 및 가드레일 프롬프트를 적용하여 산업 현장에 요구되는 신뢰성과 안전성을 확보하고자 한다.

2. 과제의 필요성 및 기대효과

(1) 기존 기술(과제)의 현황, 문제점 및 개선방안

- **현황 및 문제점:** 현재 산업 현장의 유지보수 정보는 대부분 PDF 매뉴얼, 설비 도면, 작업 문서 등 비정형 데이터 형태로 분산되어 있으며, 장애 발생 시 작업자가 이를 직접 탐색해야 하는 비효율이 존재한다.

기존 산업 현장에서는 장애 발생 시 매뉴얼을 직접 찾거나 숙련자의 경험에 의존해야 하는 한계가 있다. 특히 중소 규모 산업 현장의 경우, 유지보수 절차가 체계적으로 문서화되지 않은 사례가 많으며, 작업 지식이 숙련 작업자의 경험에 의존하는 경우가 빈번하다.

이러한 원인들로 인해 초기 대응이 지연되고 작업 효율이 저하된다. 또한 미흡한 매뉴얼과 구두 전달로 작업자 간 큰 기술 편차를 발생시키며, 신규 작업자의 현장 적응 및 위기 대응 능력 확보에 큰 장애물로 작용하고 있다.

- **개선방안:** 도메인 특화 데이터(사내 매뉴얼)만을 참조하여 답변을 생성하는 RAG 아키텍처를 도입한다. AI가 자의적인 판단을 내리지 못하도록 프롬프트를 통제하고, 반드시 답변에 참고 문서명과 페이지 번호를 함께 출력하여 작업자가 결과를 직접 교차 검증할 수 있도록 한다. 또한 작업자의 응답과 설비 상태를 기반으로 단계별 점검 절차를 안내하는 Workflow 기반 AI Agent 시스템을 구축한다.

(2) 과제개발 혹은 제작에 따른 기대효과

- **경제적 측면:** 설비 장애 발생 시 원인 분석 및 조치에 소요되는 시간을 단축함으로써 설비 다운타임을 최소화하고, 생산 중단으로 인한 기업의 경제적 손실을 감소시킬 수 있다.

- **운영적 측면:** 숙련 작업자의 경험과 매뉴얼에 의존하던 지식을 표준화하고 검색을 용이하게 하여 비숙련 작업자도 보다 신속하게 대응할 수 있도록 지원하며, 작업 프로세스의 일관성과 유지보수 효율성을 향상시킬 수 있다.
- **기술적 측면:** 일반적인 생성형 AI 단독 활용 방식과 달리, 검색된 매뉴얼 정보를 기반으로 응답을 생성함으로써 산업 현장에서 요구되는 응답의 추적 가능성과 설명 가능성, 신뢰성을 확보한다.

3. 과제 목표 및 내용

(1) 과제 수행의 최종목표

정량적 목표

- RAG 검색 정확도: 테스트 예러 코드 30개 입력 시, Retrieval Top-3 Accuracy 기준 95% 이상 달성.
- 시스템 응답 속도(Latency): 산업 현장에서는 신속한 초기 대응이 중요하므로, 비동기 처리 최적화를 통해 최종 사용자 응답 지연 시간 5초 이내 달성.

정성적 목표:

- 현장 작업자가 장갑을 낀 상태에서도 직관적으로 사용할 수 있는 모바일 최적화 UI/UX 구현.
- 매뉴얼의 출처 기반 응답 및 단계별 Workflow 제어를 통한 Hallucination 최소화

(2) 과제의 내용 기술

주요 기능 (기능적 요구사항):

- **Server-side Data Ingestion:** Node.js 환경에서 PDF 매뉴얼 데이터를 파싱하고 의미 단위로 청킹(Chunking)한 후, ChromaDB의 HTTP API를 통해 벡터 데이터로 변환 및 저장.
- **Server Actions 기반 RAG 파이프라인:** 클라이언트의 요청을 받아 서버에서 직접 쿼리 임베딩 및 유사도 검색을 수행하고, 검색 결과와 현재 대화 상태를 기반으로 다음 점검 단계 및 조치 절차 생성.
- **출처 매핑 UI:** AI가 반환한 JSON 객체에서 출처 정보를 분리하여 화면에 시각적인 배지 형태로 출력.
- **대화형 Troubleshooting Workflow:** 설비 상태 및 작업자 응답에 따라 추가 질문과 점검 절차를 단계적으로 제공하는 상태 기반 Workflow 지원.
- **상태 기반 대화 관리(State Management):** 이전 점검 단계 및 작업자 응답 이력을 기반으로 현재 Workflow 상태를 유지 및 관리.

비기능적 요구사항:

- **보안 및 환경관리:** LLM API Key 및 DB 엔드포인트를 클라이언트에 노출하지 않고 .env.local 서버 환경변수로 철저히 은닉.
- **유지보수성:** UI 컴포넌트와 서버 액션 함수를 파일 단위로 엄격히 분리하여 코드 가

독성 확보.

- **Fail-safe 응답 구조:** 검색 유사도 점수가 기준 이하일 경우, AI가 임의로 조치 절차를 생성하지 않고 작업자에게 원문 매뉴얼 검토 혹은 숙련 작업자 확인을 요청하도록 설계한다.
- **Human in the loop 구조 적용:** AI는 유지보수 Workflow를 보조하는 역할만 수행하며, 최종 유지보수 판단 및 실제 작업 수행은 작업자가 직접 수행하는 Human-in-the-loop 구조를 적용한다.

(3) 한계점 및 향후 고도화 방향

본 시스템은 제한된 개발 기간 내 안정적인 MVP(Minimum Viable Product) 구현을 목표로 하므로, 초기 단계에서는 특정 설비 1~2종의 매뉴얼을 대상으로 제한적으로 동작한다. 또한 현재 버전은 PDF 기반 정적 매뉴얼 검색 중심 구조이므로, 실시간 설비 상태 데이터 및 센서 정보와의 직접 연동은 지원하지 않는다.

향후에는 다양한 설비 매뉴얼 및 유지보수 로그 데이터를 추가 학습 대상으로 확장하고, IoT 센서 데이터 및 실시간 설비 로그와 연계하여 보다 능동적인 장애 분석 및 예측 대응이 가능한 Workflow 기반 AI Agent 형태로 고도화할 계획이다.

또한 단계별 Troubleshooting Workflow의 상태 관리(State Management) 기능을 강화하여, 작업자의 응답 이력 및 이전 점검 결과를 기반으로 보다 정교한 멀티스텝 장애 대응 기능을 지원할 수 있도록 발전시킬 예정이다. 이를 통해 단순 질의응답형 챗봇을 넘어, 산업 현장의 의사결정을 보조하는 Agentic Workflow 시스템으로의 확장을 목표로 한다.

4. 추진전략 및 방법

(1) 추진전략 및 방법

본 과제는 산업 현장의 보수적인 특성(안전 최우선)과 제한된 개발 기간 내 안정적인 프로토타입 구현을 위해 '도메인 지식 기반의 신뢰성 확보(RAG)'와 '신속한 프로토타이핑(Rapid Prototyping)'을 핵심 방법론으로 채택하여 진행한다.

1) 문제 해결 접근법: RAG 가드레일 프롬프팅 도입

- 범용 AI의 최대 취약점인 환각 현상(Hallucination)을 해결하기 위해 **검색 증강 생성(RAG, Retrieval-Augmented Generation)**을 적용한다. 이를 통해 작업자는 수백 페이지 분량의 매뉴얼을 직접 탐색하지 않고도 필요한 조치 절차와 근거 정보를 신속하게 확인하고, 현재 점검 단계에 따라 다음 작업 흐름을 단계적으로 안내받을 수 있다.
- LLM이 사전 학습된 지식을 기반으로 임의 응답을 생성하지 않도록 제한하고, 오직 검색된 사내 매뉴얼 텍스트 내에서만 정답을 추출하도록 강제하는 '**가드레일 프롬프**

트 엔지니어링' 기법을 적용하여 응답의 안전성을 확보한다.

2) 자료 수집 및 데이터 전처리 방안

- **타겟 도메인 한정:** 공장 내 전체 설비가 아닌, 문제 발생 빈도가 높은 특정 설비(예: 핵심 모터 또는 펌프류) 1~2종의 공식 PDF 매뉴얼로 초기 수집 데이터를 한정하여 MVP(최소 기능 제품) 구현에 집중한다.
- **의미 기반(Semantic) 청킹:** 산업용 기술 문서는 다단 레이아웃, 표(Table), 설비 스펙 정보 등 복합 구조를 포함하는 경우가 많아 단순 텍스트 추출 방식만으로는 검색 품질 저하가 발생할 수 있다. 따라서 본 과제에서는 LLM기반 문서 구조 해석 기능을 활용하여 시각적 데이터를 마크다운 등의 텍스트로 정형화하고, 문맥 보존 중심의 의미 기반 청킹 전략을 적용하여 RAG 검색의 정확도를 극대화한다.

3) 환경 구축 및 개발 방법론

제한된 개발 기간 내 핵심 기능 중심의 안정적인 프로토타입 구현을 위해, 프론트엔드와 백엔드를 분리하는 전통적 방식 대신 단일 프레임워크(풀스택) 환경을 구축하여 네트워크 연동 및 통신 구조의 복잡도를 최소화한다.

개발 절차는 2단계의 **애자일(Agile) 스프린트**로 진행한다.

- **1주 차 (Core Logic):** 자료 수집, 텍스트 벡터화 및 핵심 RAG 검색 파이프라인 등 백엔드 로직 완성.
- **2주 차 (UI & Integration):** 작업자용 모바일 UI 구현, 시스템 통합 및 예외 처리(에러 핸들링) 집중.

4) 시스템 검증 및 평가 방안

- 현장에서 자주 발생하는 30개의 실제 예러 시나리오(Test Case)를 사전에 정의한다.
- 각 시나리오에 대해 Retrieval Top-3 Accuracy, Citation Precision, 평균 응답 시간 등을 측정하여 시스템 성능을 정량적으로 평가한다
- AI가 제시한 조치 절차와 출처 정보가 실제 매뉴얼 내용과 일치하는지 교차 검증을 수행하여 응답 신뢰성을 평가한다.
- RAGAS 기반 평가 지표(Faithfulness, Context Precision 등)를 참고하여 응답의 신뢰성과 검색 품질을 평가한다.
- 단계별 Troubleshooting Workflow 진행 중 AI의 분기 정확도 및 응답 일관성을 추가적으로 평가한다.

(2) 추진체계

팀 구성	성명	역할 및 담당 업무
팀장	이진녕	풀스택 아키텍처 설계 및 데이터 파이프라인 구축 - 단일 프레임워크 기반 전체 시스템 아키텍처 설계 및 환경 세팅 - 매뉴얼 의미 기반(Semantic) 청킹 로직 수립 및 Vector DB 적재 - 사용자 쿼리 및 Vector DB 간의 유사도 검색(RAG) 코어 로직 구현 - 정량적 평가 지표(응답 속도 등) 모니터링 및 병목 최적화
팀원	안태연	프롬프트 엔지니어링 및 UI/UX 클라이언트 개발 - 작업자 친화적인 모바일 최적화 웹 UI/UX 설계 및 컴포넌트 개발 - 매뉴얼 외 답변을 차단하는 가드레일(Guardrail) 시스템 프롬프트 작성 - AI 답변의 출처(페이지 번호) 시각화 및 시나리오별 예외 처리 구현 - 30개 실제 예러 시나리오 기반 정답 교차 검증(Cross-validation) 수행

5. 추진일정

세부내용	수행기간(일)															비고
	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	
A. 타겟 도메인 매뉴얼 수집 및 예러 시나리오 정의	■	■														시스템 아키텍처 및 요구사항 설계
B. 의미 기반 텍스트 청킹 및 Vector DB 적재			■	■	■											선행: A
C. 단일 프레임워크 코어 RAG 검색 로직 구축			■	■	■	■	■									선행: A B와 병행
D. UI 구현 및 출처 표기 뱃지 연동						■	■	■	■	■						C 초안 개발 후
E. 할루시네이션 방지용 가드레일 프롬프트 정밀 튜닝								■	■	■						선행: C
F. 시스템 통합 및 시나리오 교차 검증 (QA 테스트)											■	■	■			선행: B, D, E
G. 최종 산출물 정리 및 데모 서비스 배포														■	■	선행: F

6. 참고문헌

박건욱, 「인공지능의 발전을 통한 산업현장 근로자의 안전과 효율성 제고에 관한 연구」, 한국재난정보학회 학술발표대회 논문집, 2023.

Wang, Xiaohua et al., “Searching for Best Practices in Retrieval-Augmented Generation”, Proceedings of EMNLP 2024.

Liu, Fei et al., “Optimizing RAG Techniques for Automotive Industry PDF Chatbots: A Case Study with Locally Deployed Ollama Models”, 2024.

ChromaDB Documentation, <https://docs.trychroma.com/>

① 시스템 아키텍처 (Workflow 기반 RAG 장애 조치 AI Agent)

